Statistical Machine Learning

Agung Satrio Wicaksono | Weksi Budiaji

Department of Statistics
Sultan Ageng Tirtayasa University

Deskripsi

- Statistical machine learning berhubungan dengan algoritma untuk meningkatkan performa secara otomatis melalui “learning”.
- Mata kuliah ini adalah mata kuliah perkenalan pada beberapa konsep, teknik-teknik popular, dan algoritma di statistical machine learning. Topik yang dibahas adalah supervised learning untuk klasifikasi dan regresi, supervised learning untuk data deret waktu, dan unsupervised learning.
- Setelah mengikuti mata kuliah ini, mahasiswa akan memahami bagaimana, kenapa, dan kapan statistical learning dapat diterapkan pada kasus riil.

Bahan Kajian

- Konsep dasar machine learning
- Metode supervised klasifikasi
- Metode supervised regresi
- Metode supervised deret waktu
- Metode unsupervised

Materi Pembahasan

Sebelum UTS

1. Introduction
2. ANN
3. SVM
4. Tree
5. Random Forest
6. Project 1

Setelah UTS

1. Time Series
2. Clustering
3. Hierarchical
4. Partitioning
5. Clustering lain
6. Project 2

Pustaka

- Hastie T, Tibshirani R, and Friedman J. (2008). The Element of Statistical Learning. 2nd edition. Springer
- James G, Witten D., Hastie T., and Tibshirani R. (2015). An Introduction to Statistical Machine Learning. Springer

#1 - Introduction

- Artificial Intelligence, Machine Learning, and Deep Learning
- Statistical Machine Learning
- Supervised Learning
- Unsupervised Learning
- Key Concepts

Mana yang akan menang?



Home

Human Learning and Machine Learning – How they differ ?



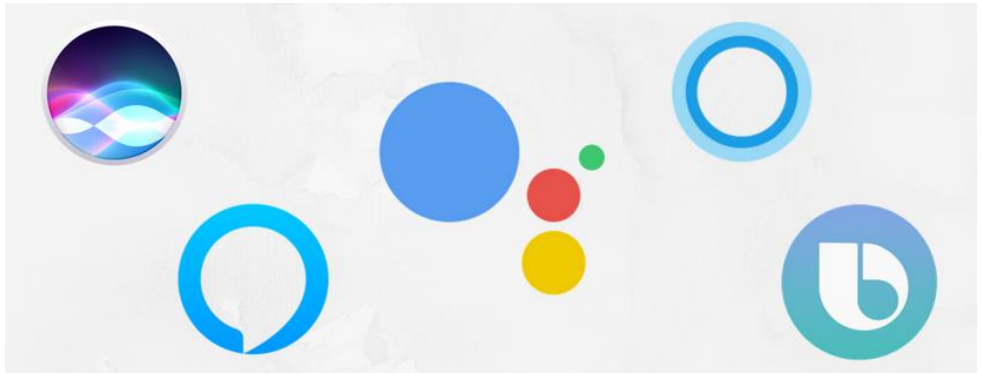
JanardhananPS | April 2, 2020 at 3:43 pm | 1 Comment

Is there any similarity in learning process between humans and machines. Human learning process varies from person to person. Once a learning process is set into the minds of people, it is difficult to change it. But, in Machine Learning (ML), it is easy to change the learning method by selecting a different algorithm. In ML, we have well defined processes to understand and estimate the accuracy in learning. Estimation of human learning is usually done through examinations and it cannot be considered as a measure of intelligence. Let us examine the difference between human and machine learning process in detail in this blog.

Humans acquire knowledge through experience either directly or shared by others. Machines acquire knowledge through experience shared in the form of past data. We have the terms, Knowledge, Skill, and Memory being used to define intelligence. Just because you have good memory, that does not mean you are intelligent. And just because you are intelligent, it does not mean you should have a good memory. However, there are exceptions to these rules. Humans begin learning by memorizing. After few years, he realizes that mere capability to memorize is not intelligence. Then he practices on transforming the data stored in memory to knowledge and applies them to develop skills to solve problems faced in real life. A person with good memory and more knowledge without the required skills cannot be considered intelligent. Search engines replaces human memory and these days the focus is on acquiring intelligence by making use of data available on the web. In humans, learning speed depends on individuals and in machines, learning speed depends on the algorithm selected and the volume of examples exposed to it.

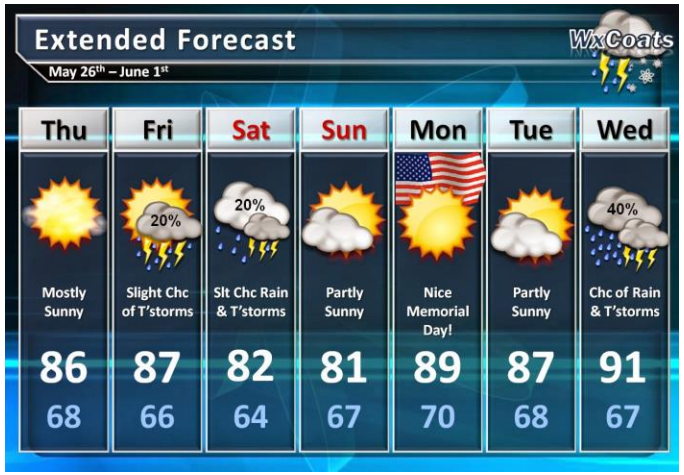
Manusia memperoleh pengetahuan melalui pengalaman baik secara langsung maupun yang dibagikan oleh orang lain. Mesin memperoleh pengetahuan melalui pengalaman yang dibagikan dalam bentuk data masa lalu. Kita memiliki istilah Pengetahuan, Keterampilan, dan Memori yang digunakan untuk mendefinisikan kecerdasan. **Hanya karena Anda memiliki ingatan yang baik, bukan berarti Anda cerdas.**

Artificial Intellegence, Machine Learning, dan Deep Learning



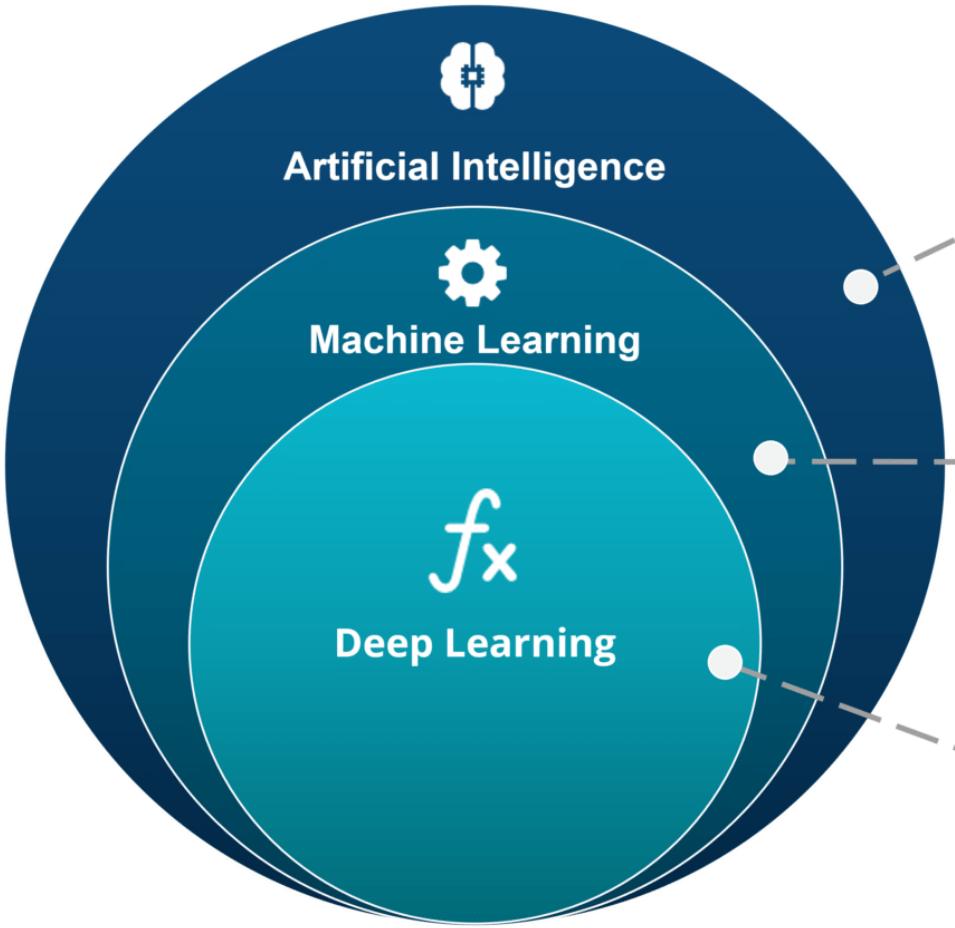












ARTIFICIAL INTELLIGENCE

A technique which enables machines to mimic human behaviour

MACHINE LEARNING

Subset of AI technique which use statistical methods to enable machines to improve with experience

DEEP LEARNING

Subset of ML which make the computation of multi-layer neural network feasible

Secara Hierarki:

- **Artificial Intelligence (AI)** – Konsep besar tentang mesin yang bisa meniru kecerdasan manusia. Contoh: Robot, Virtual Assistant
- **Machine Learning (ML)** – Subset dari AI yang memungkinkan sistem belajar dari data tanpa diprogram secara eksplisit. Contoh: Deteksi Spam, Prediksi Cuaca, Rekomendasi Film & Lagu
- **Deep Learning (DL)** – Subset dari ML yang menggunakan jaringan saraf tiruan (Neural Networks) dengan banyak lapisan. Contoh: Pengenalan Wajah, Self-Driving Cars

Apa itu Machine Learning?







"Machine learning is a subfield of artificial intelligence (AI) that allows systems to learn from data, identify patterns, and make decisions with minimal human intervention."

Ian Goodfellow, Yoshua Bengio, Aaron Courville (2016).

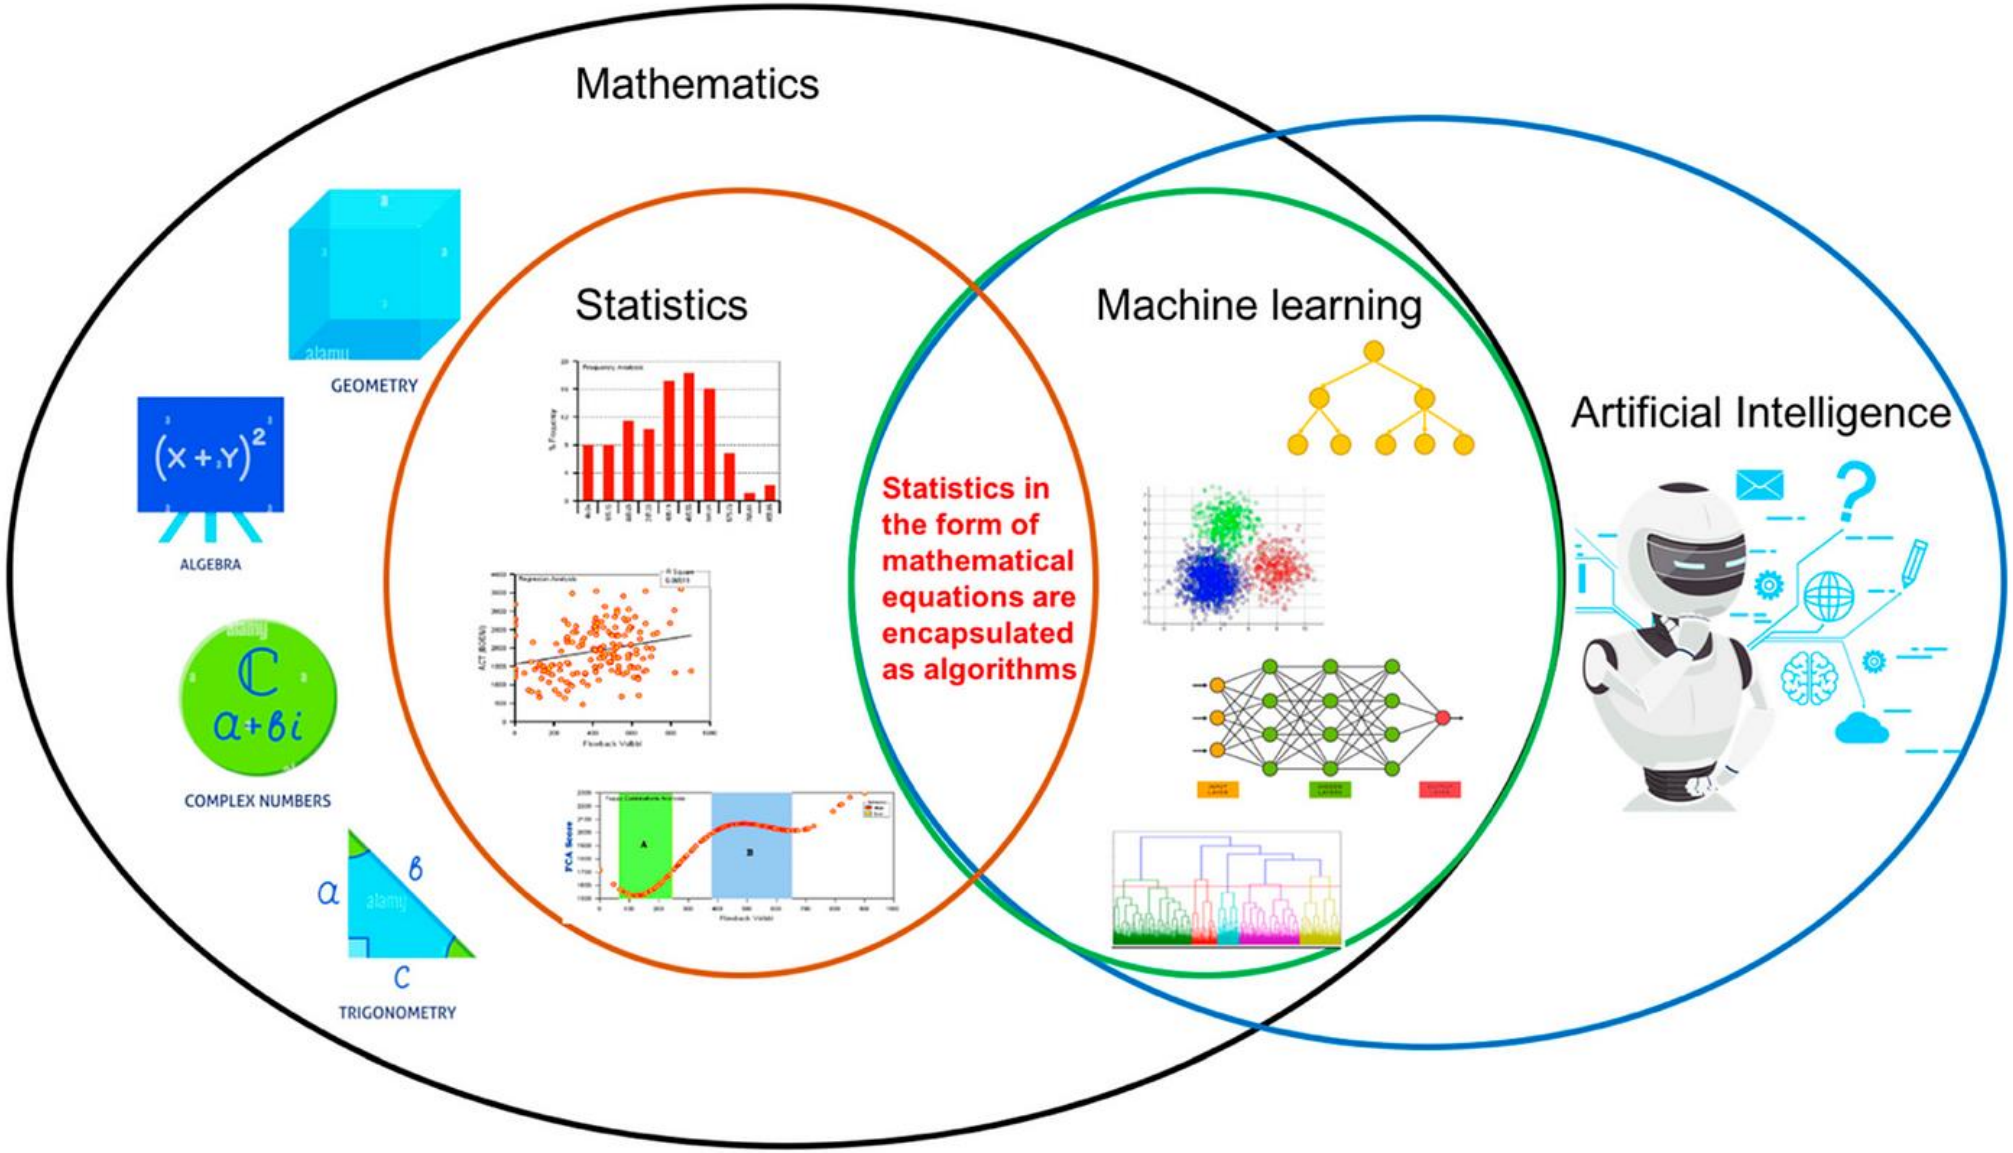
Pembelajaran mesin adalah subbidang kecerdasan buatan (AI) yang memungkinkan sistem untuk belajar dari data, mengidentifikasi pola, dan membuat keputusan dengan sedikit intervensi manusia.

Apa itu Machine Learning?

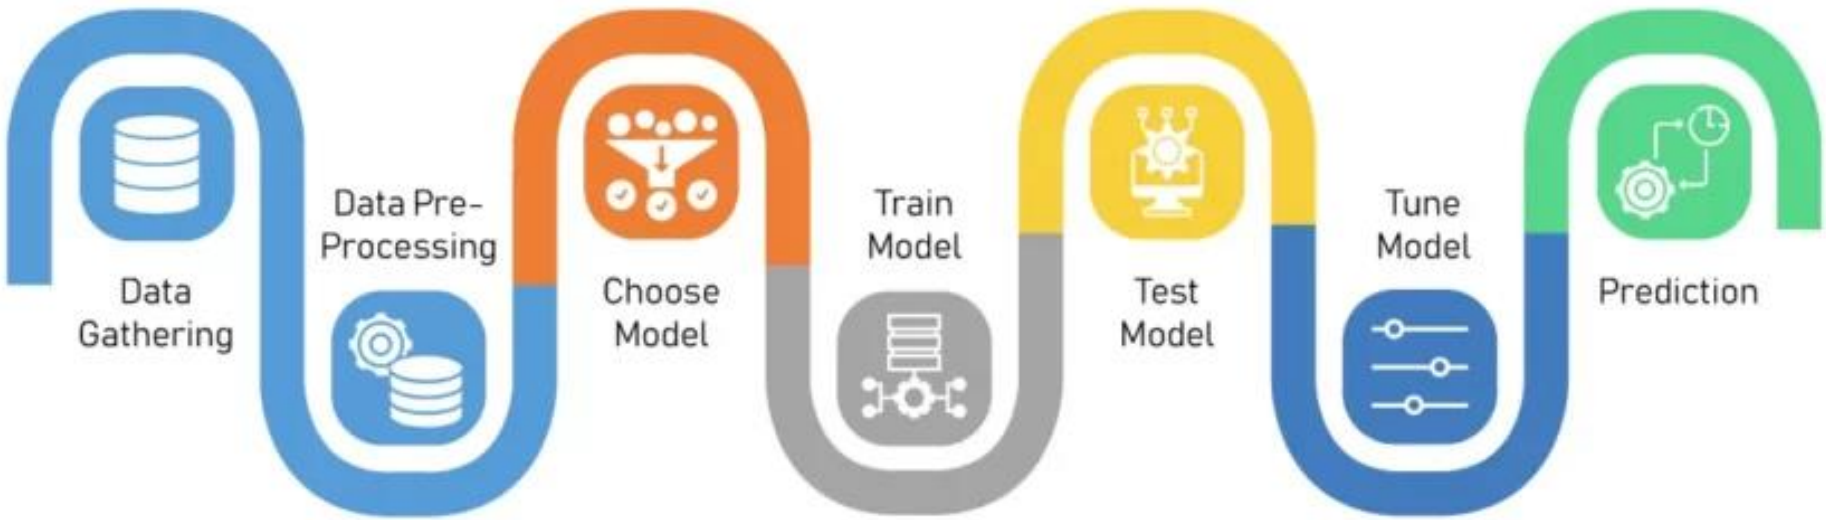
- Lebih mudahnya, **Machine Learning (ML)** adalah cabang dari kecerdasan buatan atau Artificial Intelligence (AI) yang memungkinkan sistem komputer untuk belajar dari data dan pengalaman tanpa harus secara eksplisit diprogram.
- Dengan menggunakan berbagai algoritma dan teknik-teknik statistika, ML memungkinkan komputer untuk mengidentifikasi pola-pola dalam data, membuat prediksi, dan mengambil keputusan secara mandiri.

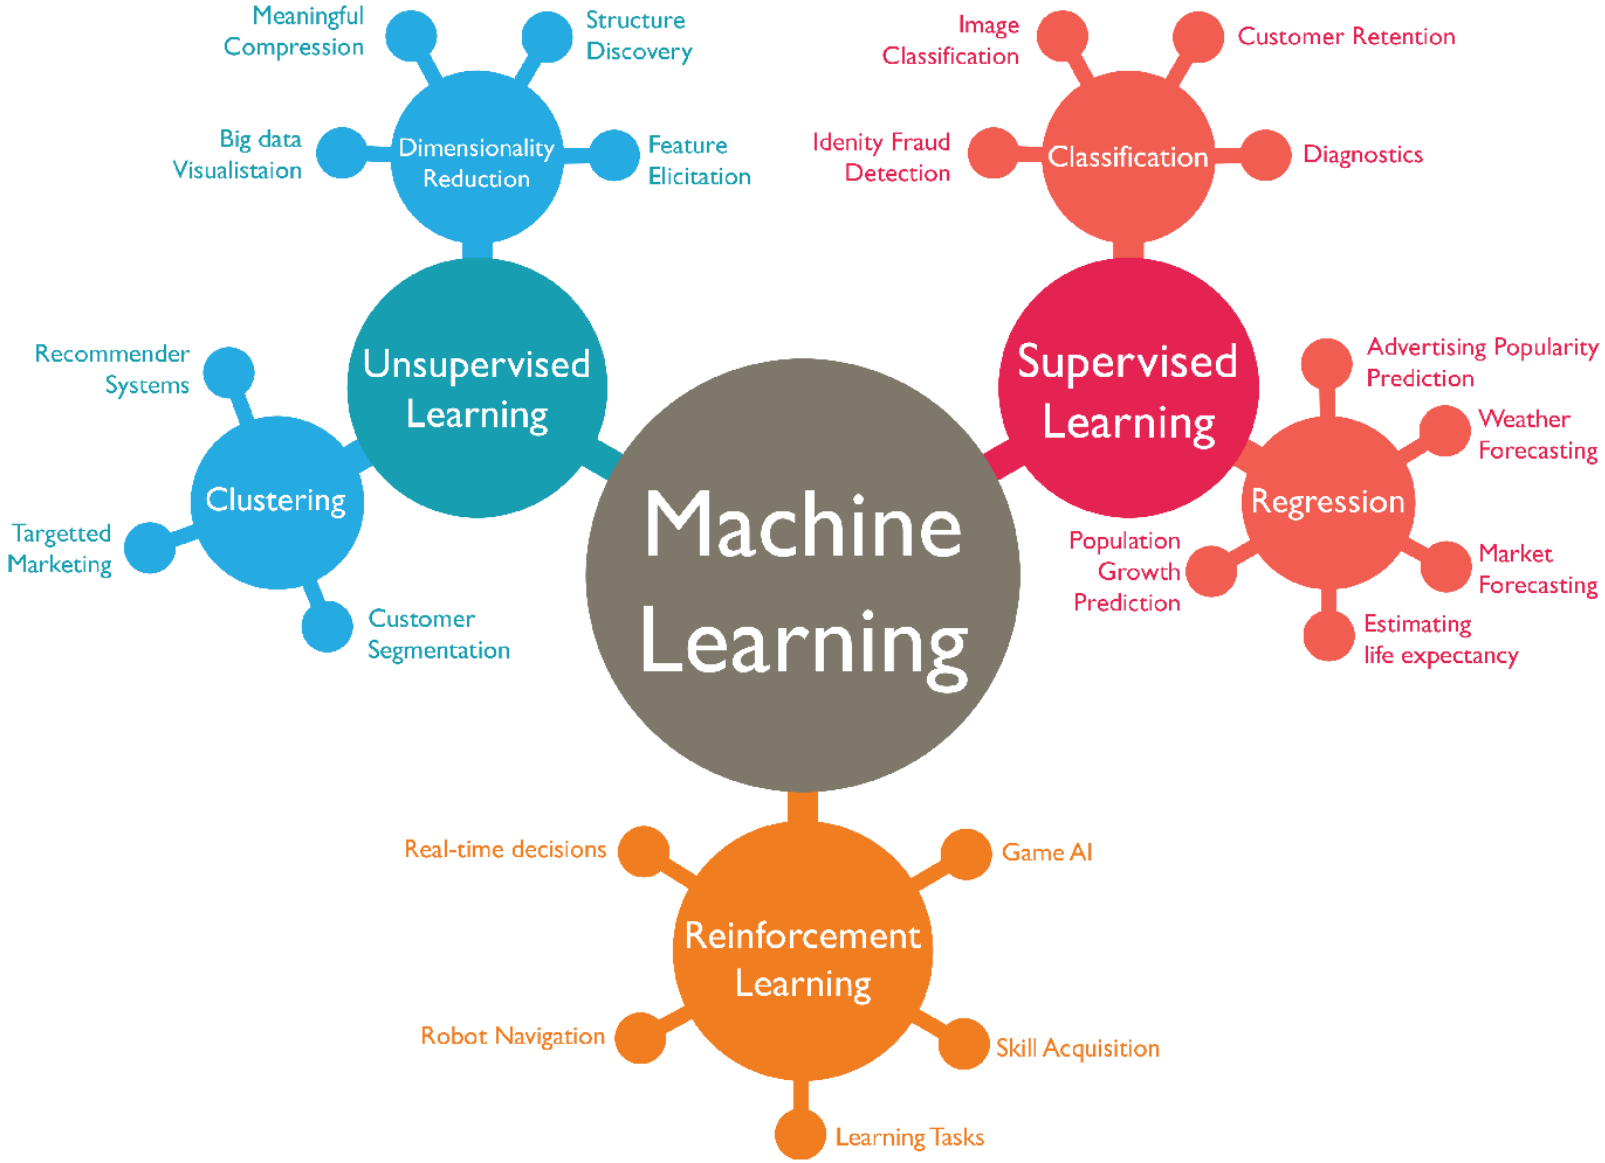
What is Statistical Machine Learning?

- **Statistical machine learning** involves using statistical techniques to develop models that can learn from data and make predictions or decisions.
- In essence, statistical machine learning merges the computational efficiency and adaptability of machine learning algorithms with statistical inference and modeling capabilities.
- Supervised, unsupervised, and semi-supervised learning– they all rely on a solid statistical foundation.
- By employing statistical methods, we can extract significant patterns, relationships, and insights from intricate datasets, thereby promoting the effectiveness of machine learning algorithms.

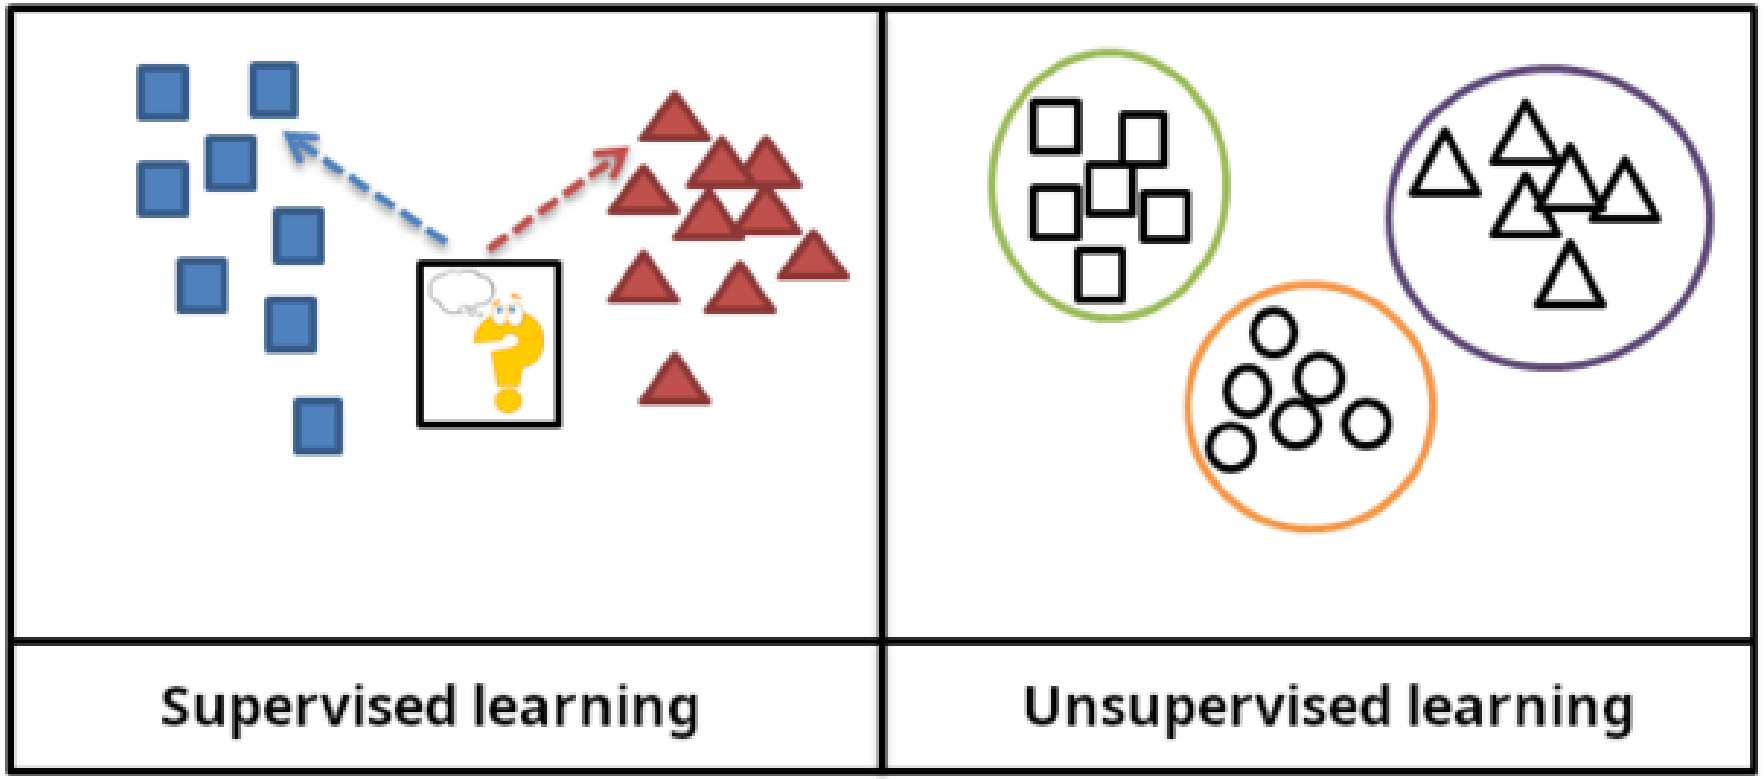

Mathematics
GEOMETRY
ALGEBRA
COMPLEX NUMBERS
TRIGONOMETRY
Statistics
Statistics in the form of mathematical equations are encapsulated as algorithms
Machine learning
Artificial Intelligence

Proses Machine Learning




Machine Learning
Unsupervised Learning
Dimensionality Reduction
Meaningful Compression
Structure Discovery
Big data Visualistaion
Feature Elicitation
Clustering
Recommender Systems
Targetted Marketing
Customer Segmentation
Supervised Learning
Classification
Image Classification
Customer Retention
Idenity Fraud Detection
Diagnostics
Regression
Advertising Popularity Prediction
Weather Forecasting
Population Growth Prediction
Market Forecasting
Estimating life expectancy
Reinforcement Learning
Real-time decisions
Game AI
Robot Navigation
Skill Acquisition
Learning Tasks

Supervised vs Unsupervised Learning



Supervised Learning

Pada supervised learning, model dilatih menggunakan data yang sudah diberi label (target atau output yang diinginkan). Tujuan utamanya adalah memprediksi output berdasarkan input yang diberikan.

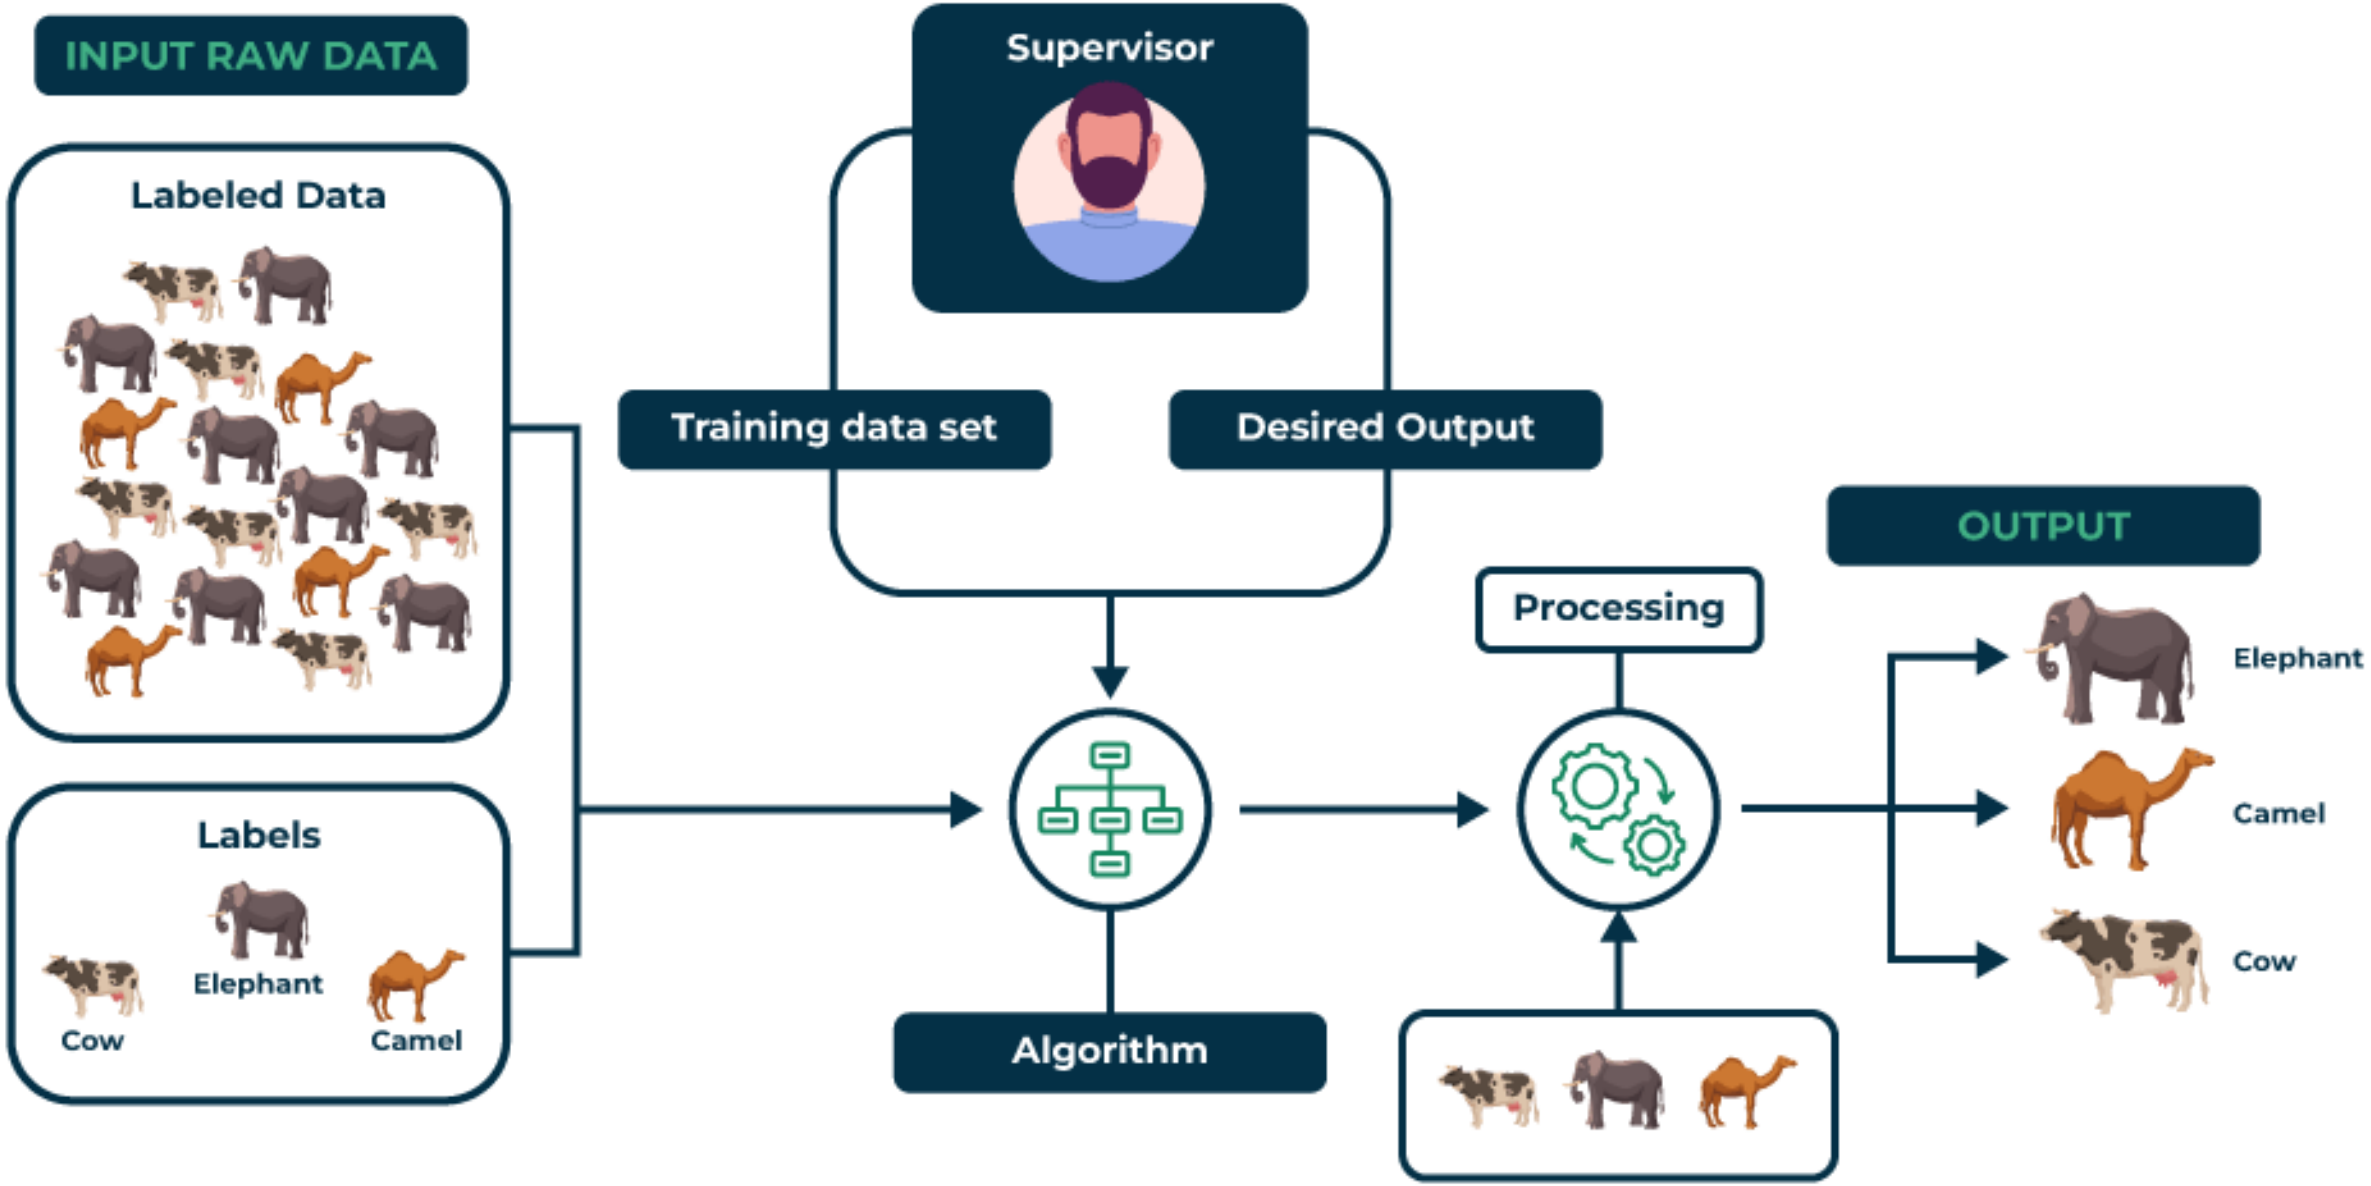
Proses: Model belajar dengan cara membandingkan prediksi yang dihasilkan dengan label yang benar, kemudian memperbaiki kesalahan prediksi melalui proses iteratif (seperti gradient descent).

Contoh:

- **Regresi**: Memprediksi harga rumah berdasarkan fitur seperti ukuran dan lokasi.
- **Klasifikasi**: Menentukan apakah email adalah spam atau bukan berdasarkan fitur tertentu (kata-kata dalam email).

Keuntungan: Model menghasilkan prediksi yang lebih akurat karena ada pengawasan dalam proses pelatihan.

Supervised Learning



Contoh Kasus Supervised Learning

Permasalahan Klasifikasi:

- **Deteksi Penyakit**: Prediksi apakah pasien menderita penyakit tertentu. Fitur Data: Usia, Jenis Kelamin, Gejala, Hasil Tes Medis, Riwayat Keluarga, Gaya Hidup.
- **Klasifikasi Spam Email**: Prediksi apakah email spam atau bukan.. Fitur Data: Kata-kata dalam Subjek, Isi Email, Pengirim, Panjang Email, Tautan/Lampiran.

Permasalahan Regresi:

- **Prediksi Harga Rumah**: Prediksi harga rumah berdasarkan fitur seperti ukuran dan lokasi. Fitur Data: Luas Rumah, Jumlah Kamar Tidur, Lokasi, Usia Rumah, Fasilitas, Keamanan.
- **Prediksi Pengeluaran**: Prediksi pengeluaran bulanan berdasarkan pendapatan dan faktor lain. Fitur Data: Pendapatan, Pekerjaan, Lokasi, Status Perumahan, Jumlah Tanggungan, Gaya Hidup

Unsupervised Learning

Dalam unsupervised learning, model dilatih menggunakan data yang **tidak diberi label**. Tujuan utama adalah menemukan struktur, pola, atau hubungan tersembunyi dalam data.

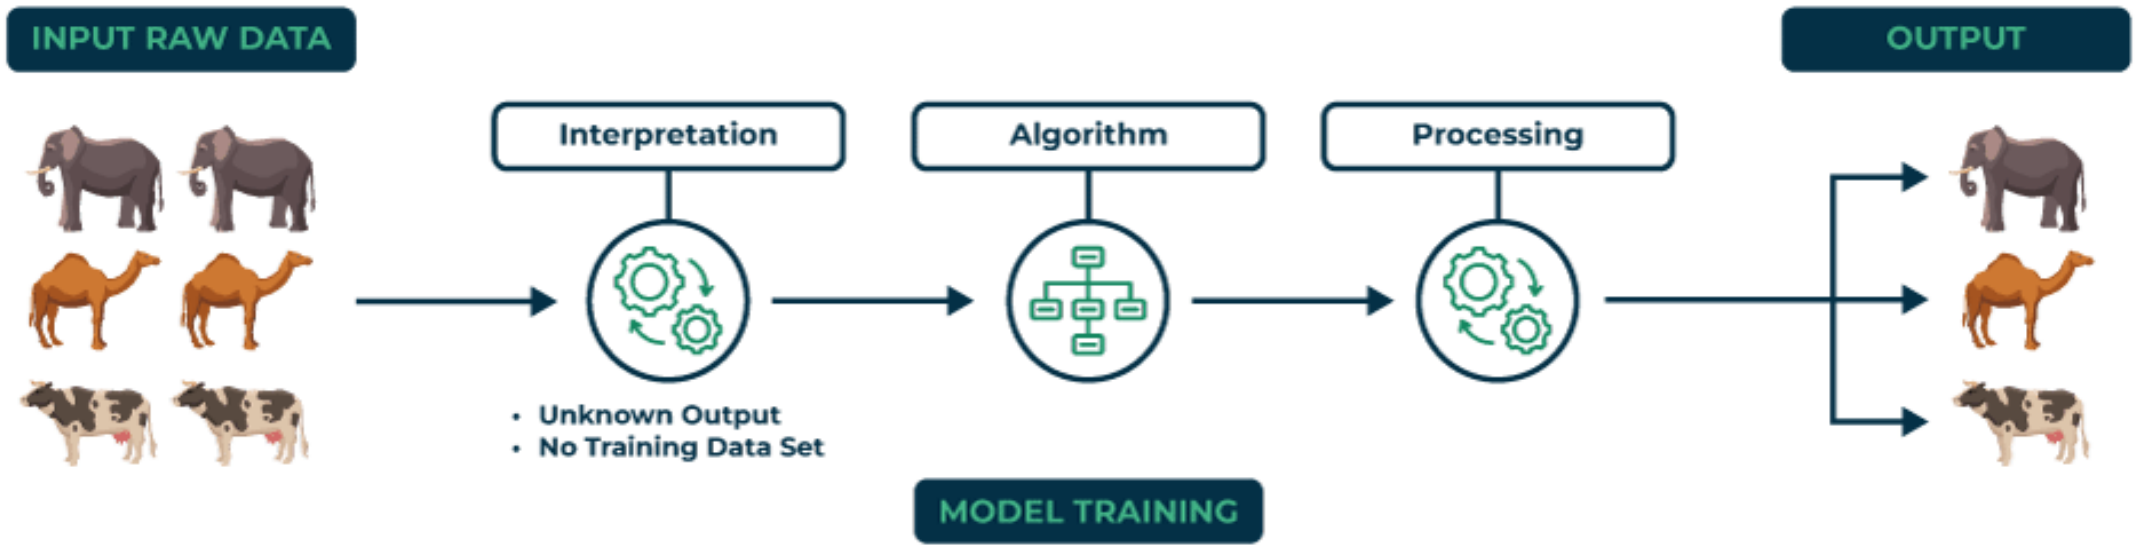
Proses: Model mencoba mengelompokkan atau mengelompokkan data berdasarkan kesamaan atau pola yang ada tanpa bantuan label.

Contoh:

- **Clustering**: Mengelompokkan pelanggan berdasarkan perilaku pembelian mereka tanpa mengetahui kategori yang ada.
- **Reduksi Dimensi**: Mengurangi jumlah fitur dalam dataset tanpa kehilangan informasi yang penting (misalnya, PCA - Principal Component Analysis).

Keuntungan: Tidak memerlukan data berlabel, yang sering kali lebih sulit didapat.

Unsupervised Learning



Contoh Kasus Unsupervised Learning

- **Klastering Pelanggan:** Mengelompokkan pelanggan berdasarkan perilaku pembelian. Fitur Data: Umur, Penghasilan, Frekuensi Pembelian.
- **Reduksi Dimensi:** Mengurangi jumlah fitur untuk visualisasi data yang lebih mudah. Fitur Data: Fitur gambar (misalnya, piksel), Data multi-dimensi.
- **Deteksi Anomali:** Mendeteksi pola yang tidak biasa dalam data (misalnya fraud). Fitur Data: Transaksi, Waktu, Jumlah Pembelian.

Supervised vs Unsupervised Learning

Aspect	Supervised Learning	Unsupervised Learning
Definition	Learning with labeled data to predict the output	Learning with unlabeled data to find hidden patterns or structure
Goal	Predict output values based on known inputs	Discover hidden structure or patterns in the data without labels
Example Algorithms	- Linear Regression - Classification (SVM, Decision Tree)	- Clustering (K-means, DBSCAN) - Dimensionality Reduction (PCA)
Output Type	Output is a label or continuous value (e.g., category or number)	Output is groups or clusters (e.g., data segmentation)
Data Used	Labeled data (inputs and outputs are known)	Unlabeled data (only inputs, no known outputs)
Example Applications	- House price prediction - Email spam classification	- Market segmentation - Image analysis (e.g., pattern recognition)
Advantages	More accurate predictions due to reference for training	Doesn’t require labeled data, more flexible in exploring data
Example Output	- Spam or not spam category - Price prediction	- Clusters of customers with similar behaviors - Simplified dimensions

Konsep Statistika yang menjadi core ML

- Probability
- Descriptive Statistics
- Sampling
- Estimation
- Hypothesis Testing
- Cross Validation

Istilah Dasar

- Variabel
- Feature
- Instance
- Data Training
- Data Testing

Variabel

- Variabel adalah atribut atau karakteristik yang dapat berubah dan digunakan untuk mewakili suatu data dalam analisis atau pemodelan. Dalam statistika dan machine learning, variabel dapat berupa:
- **Variabel Independen (Predictor/Feature)**: Variabel yang digunakan untuk memprediksi nilai variabel lain.
- **Variabel Dependen (Target/Label)**: Variabel yang diprediksi berdasarkan variabel independen.

Feature

- Feature adalah atribut atau kolom dalam dataset yang digunakan sebagai masukan dalam model machine learning. Setiap feature mewakili karakteristik spesifik dari instance data.
  Contoh:
- Pada dataset harga rumah, fitur bisa berupa luas tanah, jumlah kamar, dan lokasi.
- Pada dataset klasifikasi email, fitur bisa berupa jumlah kata dalam email atau keberadaan kata-kata tertentu.



Instance (Observasi/Data Point)

- Instance adalah satu contoh atau satu baris data dalam dataset. Setiap instance memiliki nilai untuk setiap fitur.

Contoh:

- Pada dataset harga rumah, satu rumah dengan luas 100m^2, 3 kamar tidur, dan lokasi di pusat kota merupakan satu instance.
- Pada dataset klasifikasi email, satu email individu adalah satu instance.

Data Training & Testing

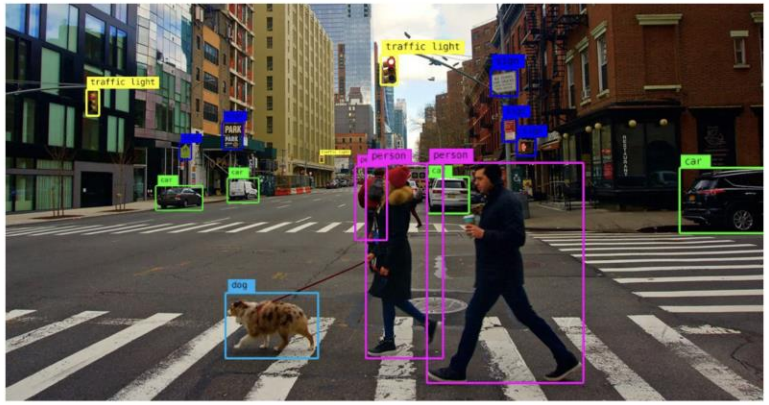
- Training data adalah sekumpulan data yang digunakan untuk melatih model machine learning. Model belajar dari pola dalam data ini untuk membuat prediksi di masa depan.
- Test data adalah sekumpulan data yang digunakan untuk menguji performa model setelah model dilatih. Data uji tidak digunakan dalam pelatihan model untuk menghindari *overfitting*.

Contoh:

- Jika kita ingin membuat model yang memprediksi harga rumah, data yang berisi luas tanah, jumlah kamar, lokasi, dan harga akan digunakan sebagai training data.
- Model yang telah dilatih dengan data harga rumah diuji menggunakan data rumah lain yang belum pernah dilihat oleh model untuk mengukur akurasi prediksinya (data testing).

Mari Telaah.

Setelah belajar tentang AI, ML, DL, Supervised & Unsupervised Learning, apa yang anda pikirkan dari 6 gambar berikut? Tuliskan dalam kertas selembar. Deskripsikan pikiran anda minimal 30 kata per gambarnya.











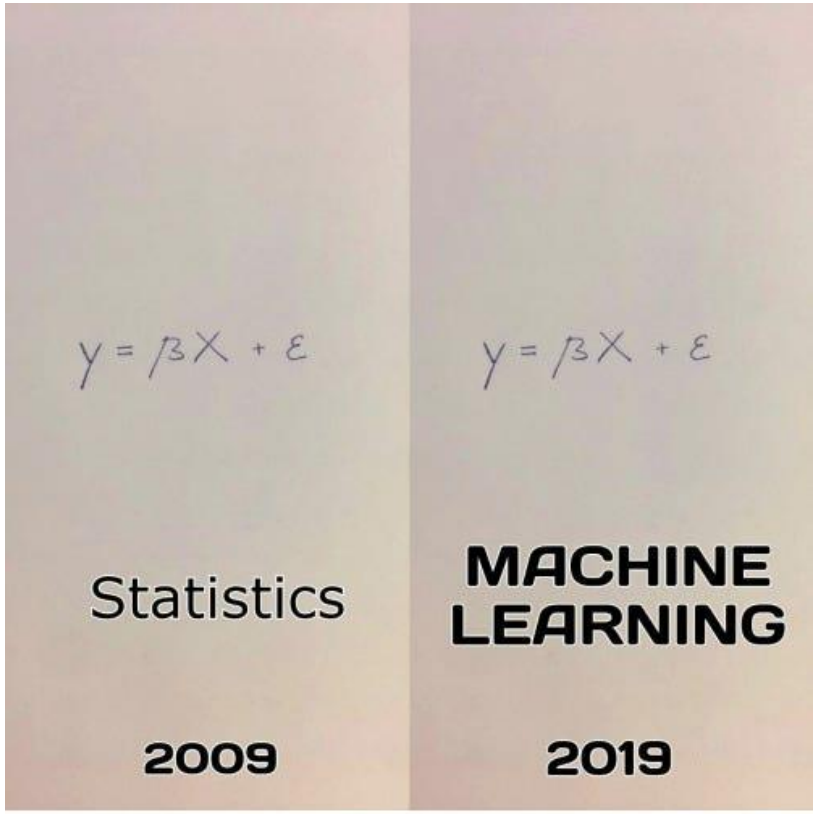


Tugas

- What is *overfitting* in machine learning?

Terima Kasih





#10yearchallenge

